

Diseño Experimental

Benchmark multifactorial de QCNN para clasificación de imágenes bajo restricciones NISQ

14 de agosto de 2026

Un **framework de benchmarking**, no la implementación de una QCNN en particular. Las arquitecturas concretas se integran como adaptadores externos, y el núcleo del sistema (datos, ejecución, métricas, estadística) no depende de ninguna arquitectura específica.

Pregunta de investigación

Cómo se comportan las QCNN al pasar de una simulación analítica idealizada a condiciones NISQ realistas: número finito de shots, ruido de hardware y conectividad limitada de qubits.

Principios de diseño

Fidelidad metodológica, reproducibilidad, modularidad y separación entre la política del benchmark y la lógica propia de cada modelo.

Decisión de diseño	Consecuencia
Configuración declarativa (Pydantic, YAML)	Cada experimento queda resuelto en un objeto inmutable con hash canónico, reproducible entre máquinas.
Registro de plugins con adaptadores	Nuevos modelos, datasets o ruidos se añaden sin modificar el núcleo del benchmark.
Ejecución determinista	Todas las semillas derivan de una semilla raíz. Ninguna parte del código lee estado aleatorio implícito.

Modelos evaluados

Modelo	Arquitectura
QCNN Hur (Ansatz 8)	8 qubits de datos, sin ancillas. Tres etapas convolución-pooling ($8 \rightarrow 4 \rightarrow 2 \rightarrow 1$) con parámetros compartidos. Pooling controlado (R_z , R_x). Lectura en base de Pauli-Z.
QCNN Wei (amplitud)	10 qubits de trabajo + 4 ancillas. Filtro convolucional 3×3 con 9 parámetros entrenables. Pooling que ignora los qubits de trabajo 4 y 9. Lectura mediante un hamiltoniano de 37 parámetros (identidad, Z, ZZ) con salida sigmoide.
Regresión logística	Penalización L2, solver lbfgs, 2000 iteraciones. Entrenada sobre la misma representación que el modelo cuántico con el que se compara.
CNN compacta	Conv2D(1,8)→ReLU→AvgPool → Conv2D(8,16)→ReLU→AvgPool → GlobalAvgPool → Lineal(16,1) → Sigmoide. Sin batch norm, dropout, augmentación ni pesos preentrenados.
QCNN	QCNN del paper fundamental.

Las dos QCNN reproducen los circuitos originales de Hur et al. y Wei et al. Las líneas base clásicas fijan un piso de comparación bajo el mismo protocolo de entrenamiento.

Tarea	Representación	Codificación cuántica
MNIST 1 vs. 8	PCA densa (Hur), 16 componentes, escalado a $[0, \pi]$	8 qubits, codificación densa (8 componentes por eje de Bloch)
Fashion-MNIST camiseta vs. pantalón	Imagen de amplitud (Wei), padding $28 \times 28 \rightarrow 32 \times 32$, norma L2	10 qubits de trabajo, 1024 amplitudes

Partición fija: 500 entrenamiento / 250 validación / 500 prueba por clase, semilla de muestreo 20260802, balanceada y reproducible.

Optimización

- Pérdida: entropía cruzada binaria.
- Adam, tasa de aprendizaje 0.01, $\beta_1 = 0.9$, $\beta_2 = 0.999$.
- 200 actualizaciones de parámetros, lote de 25 muestras.
- Recorte de gradiente global a norma 5.0.

Control y repetición

- Early stopping: paciencia de 5 chequeos, $\delta = 10^{-4}$.
- Inicialización: Hur uniforme en $[-\pi, \pi]$, Wei normal $(0, 0.1)$.
- 10 semillas de ejecución fijas por configuración.
- Selección del checkpoint por menor pérdida de validación.

Diseño experimental

Regímenes de ejecución, ruido y matriz de experimentos

Regímenes de ejecución (restricciones NISQ)

Régimen	Descripción	Configuración
E0	Analítico, sin ruido	Simulación exacta de estado, usada para entrenamiento y evaluación de referencia
E1	Shots finitos, sin ruido	256 / 1024 / 4096 shots por circuito medido
E2	Shots finitos con ruido	1024 shots, transpilado a un mapa de acoplamiento fijo de 16 qubits (nivel de optimización 2, SABRE)

Condiciones de ruido (siete, aplicadas solo a las QCNN):

- Ninguna (referencia sin ruido).
- Aisladas: despolarizante, error de lectura, relajación térmica.
- Compuestas: baja, media y alta severidad (combinan los tres canales anteriores).

Matriz de experimentos definida

Experimento	Alcance	Propósito
reproduce-hur	1 tarea, 1 modelo, E0	Validar la fidelidad de la implementación de Hur frente al resultado publicado
reproduce-wei	1 tarea, 1 modelo, E0	Validar la fidelidad de la implementación de Wei frente al resultado publicado
benchmark-core	2 tareas, 4 modelos, E0 y E1 (3 presupuestos de shots)	Matriz central sin ruido
benchmark-noise	2 tareas, 2 QCNN, E2, 7 condiciones de ruido	Evaluación de robustez bajo ruido
benchmark-full-v1	Unión completa de las anteriores, transpilado	Matriz normativa v1.0 completa

Cada archivo declara el alcance de componentes en juego. El cálculo del producto cruzado tarea $\times$ representación $\times$ modelo $\times$ ejecución $\times$ ruido corresponde a la planeación de experimentos, aún pendiente de implementación.

Análisis de resultados

Métricas y validación estadística

Predictivas

Desempeño de clasificación sobre el conjunto de prueba.

Convergencia

Comportamiento del entrenamiento a lo largo de las actualizaciones.

De recursos

Métricas derivadas de qubits, parámetros, profundidad y shots.

Robustez

Degradación del desempeño y tasa de fallo de corridas bajo ruido.

Método	Uso previsto
Intervalos de confianza bootstrap BCa	Cuantificar la incertidumbre de cada métrica a través de las 10 semillas de ejecución
Test pareado de permutación de signo	Comparar modelos o condiciones bajo el mismo protocolo, sin supuestos distribucionales
Corrección de Holm	Controlar el error de tipo I al hacer comparaciones múltiples
Tamaños de efecto pareados (d_z , probabilidad de superioridad)	Reportar la magnitud de las diferencias, no solo su significancia

Completo

- Esquema de configuración y validación.
- Registro de plugins.
- Descarga, verificación y muestreo estratificado de datasets.
- Ajuste y transformación de representaciones (PCA densa, amplitud).
d

Pendiente

- Adaptadores de modelo (Hur, Wei, líneas base clásicas).
- Ciclo de entrenamiento.
- Motor de ejecución, ruido y transpilación.
- Métricas, análisis estadístico y reporte.

320 pruebas automatizadas en ejecución continua. El pipeline de datos y representaciones es reproducible de extremo a extremo, con hashes verificables.

Un **framework de benchmarking reproducible y extensible** para QCNN bajo restricciones NISQ.

Propiedad	Cómo se logra
Reproducible	Configuración inmutable con hash canónico, semillas derivadas de una raíz, provenance registrado en cada corrida.
Extensible	Nuevos modelos, datasets, ruidos o métricas se integran como plugins, sin tocar el núcleo del benchmark.
Metodológicamente fiel	Los adaptadores reutilizan las implementaciones originales de Hur et al. y Wei et al., en vez de reescribir los circuitos.
Comparable	Mismo protocolo de entrenamiento, mismas particiones y mismo presupuesto de cómputo para modelos cuánticos y clásicos.