

Benchmark reproducible de QCNN bajo condiciones NISQ

Presentacion de avance de investigacion

Estudiante: Mariel Alvarez Salas
Director: Dr. Leonardo Ledesma Dominguez
Programa: Next Generation Scientists (NGS)
Fecha: 17 de septiembre de 2026

2. Agenda

3. Contexto y pregunta de investigacion
4. Diseno experimental
5. Arquitecturas evaluadas
6. Resultados E0A
7. Quantum Advantage
8. Validez de la aportacion (E0B)
9. Resultados E1 (shots finitos)
10. Proximos pasos
11. Cierre

3. Contexto y pregunta de investigacion

Pregunta central

Que tan robustas son las conclusiones sobre el desempeño de una QCNN cuando se transita de una simulacion analitica ideal a condiciones NISQ realistas: numero finito de shots, ruido de hardware y conectividad limitada de qubits.

Lo que este proyecto no es

No busca proponer una arquitectura QCNN nueva. El punto de partida son cuatro arquitecturas ya publicadas.

Lo que este proyecto es

Un framework de benchmarking reproducible: configuracion declarativa con hash canonico, seeds derivadas de una semilla raiz y separacion entre el nucleo del benchmark y la logica propia de cada modelo.

4. Diseno experimental

Fase		Pregunta que responde	Estado		
E0A		Cual QCNN de la literatura (Hur, Wei, Gong) tiene mejor desempeno en simulacion analitica, sobre los tres datasets del diseno vigente.	Completo.	45	corridas.
Quantum Advantage	Ad-	El QCNN ganador de E0A, supera a una CNN clasica con conteo de parametros comparable.	Completo.	30	corridas.
E0B		El QCNN ganador de E0A, supera a una QCNN generica sin sesgo de diseno (Cong et al.).	Completo.	30	corridas.
E1		Como se degrada el desempeno del QCNN ganador al pasar a shots finitos (256, 1024, 4096).	Completo.	45	corridas.
E2		Como se degrada el desempeno bajo ruido de hardware y restricciones de conectividad, sobre shots finitos.	Motor construido y validado. Matriz completa pendiente.		

4. Diseno experimental: cobertura de modelos por fase

Fase		Modelos evaluados	Corridas
E0A		Los 3 candidatos de la literatura, Hur, Wei y Gong.	45
Quantum Advantage	Ad-	Solo el ganador de E0A, contra su CNN analogica clasica.	30
E0B		Solo el ganador de E0A, contra Cong, la QCNN generica de referencia.	30
E1		Solo el ganador de E0A, mas Cong si aplica.	45
E2		Solo el ganador de E0A, mas Cong si aplica.	Pendiente

Por que las fases posteriores a E0A no repiten los 3 candidatos

Con 5 semillas por configuracion, un test de permutacion pareado tiene poca potencia para detectar diferencias moderadas. Multiplicar por 3 el numero de comparaciones en cada fase posterior diluiria esa potencia sin responder una pregunta nueva. El costo de computo tambien crece rapido bajo shots finitos, ver la nota de viabilidad en la seccion de proximos pasos.

4. Diseno experimental: consistencia con el diseno original

Lo que el diseno original si preveia

El regimen de ruido, benchmark-noise en el diseno original, fijaba explicitamente 2 QCNN, no los 4 modelos de benchmark-core. La practica actual en E2, un ganador mas Cong, es consistente con ese punto.

Lo que cambio despues del diseno original

El diseno original, antes de agregar Gong y Cong, preveia correr benchmark-core, E0 y E1, con sus 4 modelos de esa version, las 2 QCNN de Hur y Wei mas sus 2 CNN analogas clasicas, sin un paso de seleccion de candidato. El embudo de E0A se agrego como refinamiento posterior junto con Gong y Cong, y no esta documentado en ese diseno original para la fase E1. Se mantiene aqui como decision de diseno confirmada, no como continuacion silenciosa de un plan previo.

5.1. QCNN Hur et al. (2022, Ansatz 8)

Especificacion real

8 qubits.

36 parametros entrenables.

Encoding: PCA densa a 16 componentes, angulo denso (dos componentes por eje de Bloch, "Angle-compact").

Idea central

Tres etapas jerarquicas de convolucion y pooling (8 a 4 a 2 a 1 qubits) con parametros compartidos entre aplicaciones de una misma etapa, replicando la invariancia traslacional de una CNN clasica. Lectura en base de Pauli-Z de un solo qubit.

Por que se incluye

Representa el extremo de codificacion por angulo de la literatura: maximiza el numero de features por qubit sin usar codificacion de amplitud.

5.2. QCNN Wei et al. (2021)

Especificacion real

10 qubits de trabajo.

46 parametros entrenables (9 del filtro convolucional, 37 del hamiltoniano de lectura).

Encoding: amplitud directa (imagen con relleno a 32×32 , 1024 amplitudes).

Idea central

Filtro convolucional 3×3 como combinacion lineal de unitarios (LCU) sobre corrimientos de la imagen. Pooling que descarta 2 de los 10 qubits. Lectura con un hamiltoniano completo de 37 parametros (identidad, Z, ZZ), no un solo observable.

Por que se incluye

Representa el extremo opuesto a Hur: codificacion de amplitud (maxima compresion de informacion por qubit, mayor profundidad de circuito) en vez de angulo. Nota de implementacion: el registro de 4 qubits ancilla del filtro LCU del paper se reemplaza aqui por su equivalente clasico exacto para el caso sin ruido, una combinacion lineal directa, en vez de simular puertas controladas y post seleccion real.

5.3. QCNN Gong et al. (2024)

Especificacion real

8 qubits.

36 parametros entrenables (mismo Circuit 6 de la familia Hur/Sim et al.).

Encoding: tree-hybrid amplitude, bloques de 2 qubits, capacidad de 12 features (PCA a 8 componentes, relleno con ceros).

Idea central

Combina codificacion de angulo y de amplitud dividiendo los qubits en bloques pequenos. Dentro de cada bloque usa rotaciones controladas en arbol para aprovechar mejor la profundidad del circuito que el angulo denso puro, sin normalizar cada bloque por separado.

Por que se incluye

Aporta una estrategia de encoding hibrida, intermedia entre Hur (angulo denso) y Wei (amplitud pura). Permite evaluar si esa combinacion ofrece una ventaja real.

5.4. QCNN generica de Cong et al. (2019)

Especificacion real

8 qubits.

51 parametros entrenables (45 de convolucion $SU(4)$, 6 de pooling).

Encoding: angulo simple (PCA a 8 componentes, un feature por qubit).

Idea central

Arquitectura QCNN fundacional y generica. Usa el unitario de convolucion $SU(4)$, el mas expresivo posible para 2 qubits, sin ningun sesgo de diseno hacia una tarea especifica.

Por que se incluye

Sirve de referencia en E0B: verifica si la aportacion especifica del modelo ganador de E0A (encoding denso, filtro LCU o tree-hybrid) realmente aporta ventaja sobre una QCNN jerarquica generica sin ese diseno particular.

5.5. Comparativa de arquitecturas

Modelo	Qubits	Parametros	Encoding	Rol en el benchmark
Hur	8	36	PCA-16, angulo denso	Candidato (E0A)
Wei	10	46	Amplitud directa (1024)	Candidato (E0A), ganador
Gong	8	36	Tree-hybrid amplitude (PCA-8)	Candidato (E0A)
Cong	8	51	PCA-8, angulo simple	Referencia generica (E0B)

6. Resultados E0A: media $\pm$ IC 95 % (bootstrap BCa)

Dataset	Hur	Wei	Gong
coat vs shirt	73.48 % [71.98, 75.10]	77.10 % [76.68, 77.36]	74.10 % [73.42, 74.72]
4 vs 9	83.48 % [81.90, 84.18]	95.38 % [94.76, 95.74]	80.92 % [78.60, 83.20]
1 vs 0	98.92 % [98.58, 99.18]	99.24 % [98.96, 99.40]	98.74 % [98.64, 98.82]

Cinco semillas por combinacion. Protocolo identico para los tres modelos: 500 actualizaciones como techo, lote de 25, early stopping con paciencia de 5 chequeos.

6. Resultados E0A: honestidad estadística

El piso del test con $n=5$ semillas

La prueba de permutacion pareada de signo, con solo 5 semillas, tiene un p-valor minimo posible de 0.0625 antes de corregir por comparaciones multiples. Tras la correccion de Holm sobre las 9 comparaciones de E0A, ninguna alcanza $p < 0,05$, sin importar el tamano del efecto observado.

Por que se selecciono a Wei de todas formas

Wei tiene la media mas alta en los tres datasets. Su intervalo de confianza no se traslapa con el de Gong en los tres datasets, y con el de Hur en dos de tres (se traslapa en 1 vs 0). El tamano de efecto es grande donde mas importa: en 4 vs 9, Wei le gana a Hur y a Gong en 5 de 5 semillas (d_z entre 5.1 y 6.3, probabilidad de superioridad entre 0.8 y 1.0). La seleccion se basa en el conjunto de esta evidencia, no en un resultado marcado como significativo.

7. Quantum Advantage: Wei vs. CNN analoga

Dataset	Wei (QCNN)	CNN analoga	Traslape de IC
coat vs shirt	77.10 % [76.68, 77.36]	69.40 % [65.56, 72.96]	No
4 vs 9	95.38 % [94.76, 95.74]	79.42 % [69.58, 84.86]	No
1 vs 0	99.24 % [98.96, 99.40]	98.96 % [97.24, 99.62]	Si

La CNN analoga (`cnn_wei_analoga`) tiene un conteo de parametros comparable al de Wei, siguiendo el criterio de Gong et al. Tabla 4.

Significancia

Igual que en E0A, con $n=5$ semillas ninguna comparacion alcanza $p < 0,05$ tras Holm (los p ajustados son 0.19, 0.19 y 0.88). El tamano de efecto en 4 vs 9 y coat vs shirt es grande (d_z de 1.6 a 1.7, probabilidad de superioridad de 1.0), consistente con la ventaja de la QCNN, pero no formalmente significativo.

8. Validez de la aportacion (E0B): Wei vs. Cong

Dataset	Wei	Cong (generica)	Traslape de IC
coat vs shirt	77.10 % [76.68, 77.36]	73.64 % [71.80, 75.12]	No
4 vs 9	95.38 % [94.76, 95.74]	84.02 % [79.87, 87.20]	No
1 vs 0	99.24 % [98.96, 99.40]	98.74 % [98.40, 98.88]	No

Significancia

El intervalo de confianza de Wei no se traslapa con el de Cong en ninguno de los tres datasets, y el tamaño de efecto es grande en dos de ellos (d_z de 1.6 a 2.4). Aun así, tras la corrección de Holm ninguna comparación alcanza $p < 0,05$ (los tres p ajustados son 0.19). La evidencia apunta a que la aportación específica de Wei sí se traduce en ventaja sobre una QCNN genérica sin ese diseño, pero la confirmación formal sigue limitada por $n=5$.

9. Resultados E1: exactitud de Wei por presupuesto de shots

Dataset	256 shots	1024 shots	4096 shots	E0A (referencia)
coat vs shirt	63.54 %	65.34 %	68.34 %	77.10 %
4 vs 9	80.70 %	84.26 %	84.82 %	95.38 %
1 vs 0	98.42 %	98.62 %	98.64 %	99.24 %

La exactitud sube de forma monotonica con el presupuesto de shots en los tres datasets. Ninguna comparacion entre presupuestos alcanza $p < 0,05$ tras Holm ($n=5$ semillas), aunque el tamano de efecto en coat vs shirt y 4 vs 9 es grande (d_z hasta 8.4).

La columna "E0A (referencia)" **no es directamente comparable**: ver la nota metodologica en la siguiente diapositiva.

9. Resultados E1: nota metodologica importante (1/2)

Wei perdio capacidad entrenable bajo shots

En E0A y en Quantum Advantage, Wei entrena sus 46 parametros originales (9 del filtro convolucional, 37 del hamiltoniano). Bajo shots finitos, esto no fue posible: PennyLane 0.45 no admite diferenciar, con un metodo compatible con shots, un StatePrep cuyo vector de entrada depende de un parametro entrenable.

El detalle tecnico

La preparacion de estado de Wei (`MottonenStatePreparation`) exige que su vector de entrada tenga norma 1. Perturbar los 9 parametros del filtro convolucional para calcular su gradiente rompe esa norma, sin importar si el metodo de diferenciacion es parameter-shift o SPSA.

9. Resultados E1: nota metodologica importante (2/2)

La correccion aplicada

Los 9 parametros de preparacion de estado se congelan en un valor de referencia fijo. En E1 (y en E2) solo se entrenan los 37 parametros del hamiltoniano de lectura.

Consecuencia para la interpretacion

E1 no compara exactamente el mismo modelo que gano E0A, sino una version de capacidad reducida (37 de 46 parametros). La degradacion observada frente a la columna de referencia de E0A puede deberse, en parte, a esta perdida de capacidad y no unicamente al regimen de shots finitos. Separar ambos efectos queda pendiente.

10. Proximos pasos (1/3): E2 y estado de las 4 familias de metricas

E2: shots finitos con ruido NISQ

El motor de shots, ruido (despolarizante, error de lectura, relajacion termica, aisladas y compuestas) y transpilacion a un mapa de acoplamiento de 16 qubits ya esta construido y validado con pruebas de plomeria. La matriz experimental completa no se ha ejecutado.

Familia	Estado	Fecha objetivo
Predictivas	Exactitud desde el inicio. Precision, recall, F1, balanced accuracy y macro-F1 ya definidas, aplicadas desde E2. Backfill de E0, E0A, Quantum Advantage y E0B, 150 corridas, pendiente.	Backfill: fase III
Convergencia	Implementada de forma retroactiva, sin reentrenar.	Completo
De recursos	Implementada: qubits, parametros entrenables y presupuesto de shots por modelo.	Completo
Robustez	Bloqueada, depende de la matriz de E2.	Con E2

10. Proximos pasos (2/3): viabilidad de expandir E1 a Hur y Gong

Se cronometrarón actualizaciones de gradiente reales, parameter-shift, no backprop, de Hur y Gong bajo 256 shots, el presupuesto mas bajo de E1, sobre datos reales, antes de comprometerse a una matriz completa.

Modelo	Segundos por actualizacion	Matriz completa estimada (45 corridas)
Hur	62.2 s	389 h, unos 16 dias
Gong	21.0 s	131 h, unos 5 dias y medio

Por que Wei, ya ejecutado, es tan distinto

Wei diferencia coeficientes de un hamiltoniano de lectura, una expansion lineal barata. Hur y Gong diferencian los parametros del circuito completo via parameter-shift, ordenes de magnitud mas caro bajo shots.

Recomendacion: con el protocolo actual, 500 actualizaciones, lote de 25, una expansion v1.1 de E1 a los 3 candidatos no es viable dentro de la fase III. Es viable solo si se reduce el numero de actualizaciones, el tamano de lote, o el barrido de presupuestos de shots, o si se paraleliza en mas de una maquina.

10. Proximos pasos (3/3): calendario planeado vs. ejecutado

Hito (plan de trabajo)	Fecha planeada	Estado real
Benchmark E0 completo	2 sep 2026	Completado, 27 ago 2026, solo exactitud
Backfill de metricas predictivas de E0	No estaba en el plan original	En curso desde 21 sep 2026, ETA unas 6 h
Benchmark E0-E1 completo	9 sep 2026	E1 (solo Wei) completado 17 sep 2026. Ampliado a Hur+Wei+Gong: en curso desde 21 sep 2026, ETA no antes del 13 oct 2026 (22 dias, ver diapositiva anterior)
Motor NISQ (E2) validado	17 sep 2026	Validado. Bug de transpilacion para Cong encontrado y corregido 18 sep 2026
Benchmark de ruido ejecutado	23 sep 2026	No inicia hasta terminar la expansion de E1 (orden confirmado 21 sep 2026). ETA no antes de mediados de oct 2026

Las fechas de E0 y E1 (primera corrida) provienen de las marcas de tiempo de sus archivos de provenance. Las fechas ETA son proyecciones a partir de costo medido, no garantias: el early stopping puede acortarlas algo, no cambia el orden de magnitud. No se propone aqui una fecha de recuperacion para el 23 de sep: se documenta el desfase y su causa.

Agradecimientos

Al Dr. Leonardo Ledesma Dominguez, director de este proyecto, y al programa Next Generation Scientists (NGS).

Referencias principales

- Hur, T., Kim, L., Park, D. K. (2022). Quantum convolutional neural network for classical data classification. *Quantum Machine Intelligence*.
- Wei, S., Chen, Y., Zhou, Z., Long, G. (2021). A quantum convolutional neural network on NISQ devices. *arXiv:2104.06918*.
- Gong, L.-H., Pei, J.-J., Zhang, T.-F., Zhou, N.-R. (2024). Quantum convolutional neural network based on variational quantum circuits. *Optics Communications*, 550, 129993.
- Cong, I., Choi, S., Lukin, M. D. (2019). Quantum convolutional neural networks. *Nature Physics*, 15, 1273-1278.